

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHOA KHOA HỌC MÁY TÍNH

BÁO CÁO NGHIÊN CỨU ĐỒ ÁN MÔN HỌC

XÂY DỰNG VÀ TỐI ƯU HỆ THỐNG KHUYẾN NGHỊ HAI GIA ĐOẠN QUA KIẾN TRÚC STREAMING KHỐI NATIVE POLARS VÀ LIGHTGBM LAMBDA RANK

Giải pháp xử lý dữ liệu quy mô lớn dựa trên công cụ lập trình Python hiệu
năng cao

MÔN HỌC PHẦN:	Lập trình python cho máy học
MÃ LỚP HỌC PHẦN:	CS116.Q21.KHTN
SINH VIÊN THỰC HIỆN:	Hà Thanh Phong
MÃ SỐ SINH VIÊN:	24520024

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

1. TỔNG QUAN HỆ THỐNG VÀ KIẾN TRÚC PHÂN TẦNG GIAI ĐOẠN

Trong các bài toán thực tế, việc áp dụng trực tiếp các mô hình học máy phức tạp lên toàn bộ tập dữ liệu hàng triệu sản phẩm là bất khả thi do giới hạn về thời gian phản hồi (Latency). Mã nguồn đề án giải quyết thách thức này bằng cách triển khai kiến trúc khuyến nghị hai giai đoạn phối hợp (**Two-Stage Recommender System**):

- Giai đoạn 1 (Retrieval Pipeline):** Quét nhanh toàn bộ không gian sản phẩm để rút gọn danh sách từ hàng triệu xuống bể ứng viên tinh gọn chứa từ **150 - 300 sản phẩm** tốt nhất cho mỗi khách hàng, ưu tiên tối đa hóa độ bao phủ (Recall).
- Giai đoạn 2 (Reranking Pipeline):** Sử dụng bể đặc trưng hành vi chuyên sâu phối hợp cùng thuật toán học xếp hạng **LightGBM LambdaRank** để sắp xếp và chọn ra Top 10 sản phẩm gợi ý cuối cùng, tối ưu hóa độ chính xác xếp hạng (NDCG).

2. CHIẾN LƯỢC KỸ NGHỆ THỜI GIAN VÀ CƠ CHẾ KIỂM THỬ TRÁNH DATA LEAKAGE

Để mô phỏng chính xác luồng vận hành thực tế tại môi trường production, mã nguồn tịnh tiến mốc thời gian lên **01 tháng**. Việc này giúp hệ thống học dữ liệu quá khứ một cách tự nhiên và thực hiện dự đoán một cách độc lập cho tập Hidden Test diễn ra vào Tháng 1 năm sau (2026).

Thiết lập khung thời gian: Dữ liệu lịch sử từ Tháng 1 đến hết ngày 30/11/2025 được dùng làm tập xây dựng đặc trưng. Toàn bộ giao dịch phát sinh trong nội bộ Tháng 12/2025 được cô lập làm tập gán nhãn mục tiêu (Target Labels).

Hệ thống phân tách tập dữ liệu Train và Validation dựa trên nhóm người dùng (**Group-Aware Split**) thông qua hàm **.sample(fraction=0.2)** để lấy ngẫu nhiên 20% ID khách hàng làm tập kiểm thử. Phương pháp này đảm bảo toàn bộ danh sách ứng viên của một khách hàng cụ thể chỉ nằm ở một trong hai tập Train hoặc Validation, tránh hiện tượng mô hình bị quá khớp (Overfitting).

3. GIAI ĐOẠN 1: SINH ỨNG VIÊN ĐA KÊNH THÍCH ỨNG

Hệ thống tích hợp đồng thời 13 kênh trích xuất ứng viên chạy song song. Các kênh này được chia làm hai trường phái tính toán chính nhằm đa dạng hóa thuộc tính sản phẩm:

Kênh Thuật Toán Học Máy Ngầm

Triển khai phân rã ma trận tuyến tính (**Implicit ALS** , **SVD**) để trích xuất các sản phẩm có độ tương đồng cao trong không gian vector ẩn.

Kênh Thống Kê & Động Lượng

Khai thác lịch sử tương tác ngắn và dài hạn (**S1** , **S6**) kết hợp phép tính toán động lượng doanh số sản phẩm (**Momentum**) trong 30 và 45 ngày gần nhất.

3.1. Mô Hình Lọc Cộng Tác Ma Trận Hoạt Động Theo Thời Gian

Kênh **S2_als** sử dụng mô hình Alternating Least Squares để học hành vi người dùng. Trọng số tương tác cục bộ được làm mượt dựa trên khoảng cách

thời gian từ lúc phát sinh giao dịch đến thời điểm hiện tại, làm giảm tầm ảnh hưởng của các đơn hàng quá cũ:

HÀM SUY GIẢM TRỌNG SỐ TƯƠNG TÁC THEO THỜI GIAN

Công thức (3.1)

$$Weight_{u,i} = \sum \left(Quantity_{u,i} \times 0.70^{MonthsAgo} \right)$$

GIẢI THÍCH THÀNH PHẦN BIẾN SỐ

Quantity_{u,i}

Số lượng sản phẩm khách hàng *u* đã mua đối với mặt hàng *i*.

0.70^{MonthsAgo}

Hệ số suy giảm thói quen; *MonthsAgo* càng lớn (giao dịch càng cũ) thì trọng số càng nhỏ.

Kênh `D_i2i` chịu trách nhiệm tính toán ma trận tương đồng sản phẩm (Item-to-Item Similarity) trên quy mô dữ liệu lớn thông qua phép nhân ma trận thưa nguyên bản từ thư viện SciPy:

TÍNH MA TRẬN TƯƠNG ĐỒNG SẢN PHẨM TOÀN CỤC

Công thức (3.2)

$$i2i_{sim} = M_{norm}^T \cdot M_{norm}$$

CƠ CHẾ LIÊN KẾT MA TRẬN

M_{norm}

Ma trận tương tác đã được quy chuẩn hóa độ dài hình học theo chuẩn L_2 Norm.

Phép nhân tích (.)

Nhân ma trận thưa song song, kết xuất nhanh độ tương đồng Cosine của mọi cặp sản phẩm.

3.2. Thuật Toán Hợp Nhất Xếp Xạng Thích Ứng (Archetype-Aware RRF)

Thay vì áp dụng trọng số cố định, mã nguồn phân loại khách hàng thành 5 nhóm hành vi độc lập (**Archetypes**) dựa trên thói quen mua sắm. Điểm số tổng hợp của ứng viên được tính bằng thuật toán Reciprocal Rank Fusion (RRF) cải tiến, lồng ghép thêm trọng số động phụ thuộc vào nhóm khách hàng:

THUẬT TOÁN RECIPROCAL RANK FUSION TÍCH HỢP CHÂN DUNG KHÁCH HÀNG Công thức (3.3)

$$RRF_Score(u, i) = \sum_{c \in Channels} \frac{w_{a,c}}{rank_c(u, i) + 60}$$

PHÂN TÍCH THAM SỐ ĐIỀU TỐI

$w_{\{a,c\}}$

Trọng số ưu tiên của kênh gợi ý c đối với nhóm chân dung khách hàng a .

$rank_c(u, i)$

Thứ hạng của sản phẩm i được trả về bởi kênh c dành cho người dùng u .

60 (Constant)

Hằng số làm mượt danh sách, giảm thiểu ảnh hưởng tiêu cực của các sản phẩm ở vị trí rank quá thấp.

4. KỸ NGHỆ ĐẶC TRƯNG CHUYÊN SÂU HỌC MÁY

Mô hình giai đoạn 2 sử dụng một bể đặc trưng phong phú được tối ưu hóa hoàn toàn bằng Polars Engine để tăng tốc độ tính toán song song:

4.1. Kỹ Thuật Trích Xuất Độ Tuổi Trẻ Em (Text Mining Delta Age)

Hàm **`standardize_age()`** bóc tách văn bản thô từ mô tả sản phẩm thông qua biểu thức chính quy (Regex) để quy đổi kích cỡ sản phẩm (Size tã, bỉm,

quần áo) thành chỉ số số thực biểu thị số năm tuổi mục tiêu (`i_target_age_years`). Hệ thống kết hợp mốc thời gian mua hàng gần nhất để ước tính tuổi con hiện tại của khách hàng, từ đó tạo ra đặc trưng tương tác chéo:

ĐỘ LỆCH TUỔI MỤC TIÊU THỰC THỂ CHÉO (USER-ITEM AGE DELTA)

Công thức
(4.1)

$$ui_age_delta = u_child_age_estimate - i_target_age_years$$

LOGIC PHÂN HÓA CỦA ĐẶC TRƯNG

`u_child_age_estimate`

Tuổi hiện tại của con khách hàng (ước tính tịnh tiến tuyến tính từ đơn hàng quá khứ).

`i_target_age_years`

Độ tuổi sử dụng tiêu chuẩn của sản phẩm ứng viên trích xuất từ văn bản mô tả.

4.2. Chỉ Số Đa Dạng Hóa Kinh Tế Herfindahl-Hirschman (HHI)

Để đo lường định lượng mức độ trung thành của một khách hàng đối với một danh mục sản phẩm cụ thể, nghiên cứu áp dụng công thức đo lường mức độ tập trung thị trường HHI trong kinh tế học vĩ mô:

ĐO LƯỜNG ĐỘ TẬP TRUNG DANH MỤC HÀNH VI (HERFINDAHL-HIRSCHMAN INDEX)

Công thức
(4.2)

$$HHI_u = \sum_{k \in K_u} \left(\frac{Purchases_{u,k}}{Total_Tx_u} \right)^2$$

PHÂN TÍCH TOÁN TỬ TẬP HỢP

Purchases / Total_Tx

Tỷ trọng số lượng đơn hàng (Share of wallet) lọt vào phân mục sản phẩm cụ thể k .

Bình phương và tổng (Σ)

Khuếch đại tỷ trọng lớn; HHI tiệm cận mốc 1.0 đại diện cho sự tập trung thói quen mua sắm tuyệt đối.

4.3. Mô Hình Dự Báo Chu Kỳ Tái Mua (Replenishment Model)

Hệ thống tự động đo lường khoảng cách thời gian giữa các đơn hàng liên tiếp của cùng một khách hàng để tìm ra chu kỳ tái mua trung vị của sản phẩm (**i_median_replenish_gap**). Từ đó, thuật toán xác định số ngày quá hạn tiêu dùng hiện tại của khách hàng:

SỐ NGÀY VƯỢT NGƯỠNG CHU KỲ TIÊU DÙNG SẢN PHẨM

Công thức (4.3)

$$replenishment_overdue_days = ui_days_since_last - i_median_replenish_gap$$

CƠ CHẾ PHÁT TÍN HIỆU

ui_days_since_last

Số ngày trôi qua tính từ lần gần nhất khách hàng đặt mua sản phẩm này.

i_median_replenish_gap

Chu kỳ tiêu thụ trung vị tiêu chuẩn của sản phẩm trên toàn bộ hệ thống sàn thương mại.

5. GIAI ĐOẠN 2: TỐI ƯU HÓA HÀM MỤC TIÊU THỨ HẠNG LISTWISE LAMBDARANK

Thay vì tiếp cận theo hướng Pointwise phân loại nhị phân độc lập, giai đoạn 2 ứng dụng giải pháp học xếp hạng tập hợp **LightGBM LambdaRank** (Listwise Approach). Mô hình hướng tới việc trực tiếp tối ưu hóa chỉ số đánh giá thứ hạng danh sách **NDCG@10**.

Trong quá trình huấn luyện, mô hình tính toán giá trị đạo hàm ảo λ -gradient đại diện cho sự thay đổi về mặt hiệu năng (tổn thất điểm số NDCG) khi hoán đổi vị trí của cặp sản phẩm ứng viên i và j trong cùng danh sách của một khách hàng:

ĐẠO HÀM ẢO TỐI ƯU HÓA HÀM MỤC TIÊU NDCG (LAMBDA GRADIENT)

Công thức
(5.1)

$$\lambda_{i,j} = S_{i,j} |\Delta NDCG| \frac{1}{1 + e^{s_i - s_j}}$$

CẤU TRÚC GIẢI THÍCH THÀNH PHẦN

$|\Delta NDCG|$

Biên độ dao động tuyệt đối của chỉ số NDCG khi thực hiện đảo chỗ vị trí sản phẩm i và j .

$S_{i,j}$

Nhãn ưu tiên tương quan giữa hai mẫu (+1 nếu i có tương tác tốt hơn j , và ngược lại).

$1 / (1 + e^{s_i - s_j})$

Trọng số Sigmoid của hiệu số điểm dự báo hiện tại, làm giảm lực đẩy khi mô hình đã phân thứ hạng đúng.

Tham số danh sách của từng khách hàng được định nghĩa tường minh cho LightGBM thông qua mảng trường dữ liệu `group`, trích xuất song song bằng cơ chế gom nhóm của thư viện Polars.

6. KIẾN TRÚC STREAMING KHỐI THAO TÁC ĐĨA KHÔNG CHẾ BỘ NHỚ (OOM PREVENTION)

Khi xử lý toàn phần dữ liệu quy mô hàng triệu bản ghi, việc gộp chung toàn bộ ma trận ứng viên kèm bề đặc trưng hàng vi lên bộ nhớ RAM sẽ kích hoạt lỗi cạn kiệt tài nguyên hệ thống (`Out-Of-Memory`). Để khắc phục, hệ thống triển khai cơ chế điều tốc dòng chảy dữ liệu ****Disk-Based Streaming Chunk Fusion Engine****:

Cơ chế khống chế bộ nhớ: Chia nhỏ tập khách hàng duy nhất thành từng khối độc lập (mỗi khối chứa đúng 10,000 ID người dùng) để tính toán cuốn chiếu tuần tự ngay trên RAM.

Kiến trúc xử lý dữ liệu qua đĩa cứng hoạt động theo chu kỳ bốn bước lặp:

- 1. Phân khối dữ liệu:** Danh sách khách hàng mục tiêu được băm nhỏ thành các khối độc lập với kích thước cố định (`chunk_size = 10,000`).
- 2. Tính toán cục bộ trong Loop:** Các phép toán join thuộc tính tĩnh, nhân ma trận tương đồng ngầm ẩn SVD/ALS chỉ được kích hoạt nội bộ trên tập ID khách hàng thuộc khối hiện hành nhằm kiểm soát chặt chẽ dung lượng RAM chiếm dụng đỉnh.
- 3. Bộ ghi nhị phân PyArrow đẩy trực tiếp xuống đĩa:** Kết xuất dữ liệu đặc trưng của khối lập tức được chuyển đổi thành định dạng cấu trúc cột Apache Arrow thông qua hàm `.to_arrow()` và ghi nối tiếp (`Append`) xuống ổ đĩa cứng bằng thực thể `pq.ParquetWriter` phối hợp định dạng nén `SNAPPY` tốc độ cao.
- 4. Giải phóng bộ nhớ chủ động:** Các biến tham chiếu trung gian khổng lồ lập tức được gán lệnh xóa `del` ở cuối vòng lặp, kết hợp gọi trực tiếp trình thu gom rác `gc.collect()` để dọn dẹp bộ nhớ đệm, đưa đồ thị bộ

nhớ RAM quay trở về trạng thái an toàn trước khi bước vào chu kỳ của khối kế tiếp.